

课程作业 1：非结构化数据的知识图谱构建

目的：随着信息时代的到来，非结构化数据如文本、图像等海量涌现。数据治理的重点往往就是将这些非结构化数据转化为结构化的知识图谱，支持后续进一步挖掘数据中的潜在价值，为智能问答、推荐系统等诸多应用提供支持。本次作业中，需要通过实体关系提取等处理，将非结构化文本数据转换为知识图谱并存储到 Neo4j 图数据库，从而掌握行业知识图谱构建流程。

提交时间：2025.3.10 晚上 24:00 前提交 Canvas 平台

工具：

LTP: [语言技术平台 \(Language Technology Platform | LTP \)](#)

Neo4j: [Neo4j Graph Database & Analytics | Graph Database Management System](#)

数据集：

[ResumesPDF.zip • Mehyaar/Annotated_NER PDF Resumes at main](#)

业务描述及要求：

简历数据通常包含丰富的信息，如个人信息、教育背景、工作经验、技能等。这些信息是非结构化的，需要通过自然语言处理技术进行提取和结构化。通过构建知识图谱，可以将这些信息以图形的形式展现，便于查询和分析，从而为人力资源管理系统、HR 招聘系统等提供支持，实现对特定技能和工作经验的候选人的快速推荐。其大致流程如下：

[1]. **[采]** 简历读取：

从文件夹中读取简历，读取方式自行设定。并从 PDF 格式的简历文件中提取文本内容，为后续的文本分析和知识图谱构建提供数据基础。

[2]. **[治]** 知识图谱构建：

使用 LTP (Language Technology Platform) 对提取的文本进行分析，提取关键信息并构建知识图谱。(注：LTP 支持对文本进行分词、词性标注、命名实体识别、依存句法分析和语义角色标注等功能，实际使用内容自行选定) 从分析结果中提取关键信息，如工作经验、教育背景、技能等信息，为每个类别的关键信息(工作经验、教育背景、技能、项目)创建节点，并在这些节点之间创建关系，完成知识图谱的构建。

[3]. **[存]** 知识图谱存储：

使用 Neo4j 图数据库存储提取的关键信息和关系，实现知识图谱的持久化。

[4]. **[算]** 简历筛选：

支持通过知识图谱快速筛选符合特定职位要求的候选人，包括但不限于用 Neo4j Cypher 查询语言筛选出具有特定技能和工作经验的候选人。

[5]. **[用]** 展示应用：

通过实际应用展示知识图谱的构建和查询结果，在这一步骤中，编写至少两个查询示例展示如何筛选符合条件的候选人，查询结果应包括候选人的关键信息，如姓名、技能、工作经验等。

作业要求：

[1]. 个人作业，实现上述场景功能并录制运行过程和结果；

[2]. 文档所提为基础功能步骤，可根据自己的理解进行改进；

[3]. 撰写简要文档以说明流程实现过程，包括所用到的技术、关键步骤的运行结果、创新点(创新点非必须内容)等。将源代码、演示视频、说明文档打包提交到 Canvas 平台。